

潘佳阳

13715443531 | 23jypan@stu.edu.cn | 广东省佛山市



教育背景

汕头大学（本科） 数据科学与大数据技术专业 2023.09 – 至今

- GPA: 4.08/5, 专业前 10%; 英语: CET-4。
- 主修课程: 数据采集技术 (99)、多源信息融合 (96)、程序设计 (95) 等。

科研经历

人工智能安全: 面向 VLP 模型对抗攻击迁移性研究

[Accepted] Semantic Region-Guided Transferable Attacks on Vision-Language Pretraining Models

(IEEE Signal Processing Letters | JCR Q2/CCF C | 一作 | 负责: 对抗攻击实验、图表绘制和论文大纲写作)

- 论文工作: 提出语义区域引导攻击框架 SRGA, 借助外部语义先验识别视觉语义区域, 通过跨模态语义对齐、局部变换与空间加权优化实现协同扰动, 在黑盒场景下高效提升 VLP 模型对抗攻击的可迁移性, 并达成更优的迁移性-效率权衡。

[Under Review] TG-CMA: Trajectory-Guided Cross-Modal Adversarial Attacks with Neighborhood Gradient Estimation

(Pattern Recognition | 中科院一区 TOP | 学生三作 | 负责: 攻击迁移实验、图表绘制)

- 论文工作: 围绕轨迹引导跨模态攻击与邻域梯度估计开展方法设计与实验验证, 进一步探索高迁移性对抗样本生成机制。

人工智能安全: 面向 VLA 模型的隐秘对抗攻击与攻击检测研究

[Under Review] TrajCloak and TrajGuard: Stealthy Patch Attacks and Black-Box Trajectory Detection for Vision-Language-Action Models

(PRCV 2026 | CCF C | 一作 | 负责: VLA 对抗攻击实验、轨迹异常检测指标设计、实验分析)

- 论文工作: 提出面向 VLA 模型的隐秘物理补丁攻击与黑盒轨迹检测框架 TrajCloak and TrajGuard, 其中 TrajCloak 结合表征扰动、轨迹偏移约束、动作平滑正则、自适应权重调度与黑白灰低颜色复杂度补丁投影生成轨迹隐蔽的物理对抗补丁, TrajGuard 则基于动作序列特征建模干净轨迹分布并检测攻击导致的异常运动。

科研项目

广东省大创重点领域项目: 面向 VLP 模型的轨迹引导高迁移跨模态对抗攻击研究 (参与)	2026.04 – 2027.04
广东省自然科学基金面上项目: 高阶梯度优化与多策略增强驱动的对攻击样本迁移机制研究 (参与)	2026.01 – 2028.12
中国高校产学研创新基金 (AI 网络安全治理技术): AI 视觉系统高迁移性对抗攻击与安全检测方法研究 (参与)	2026.04 – 2027.03

学科竞赛

2025 RoboCom 睿抗机器人开发者大赛 – 编程设计赛道	全国一等奖	2025.08
ICPC 国际大学生程序设计竞赛全国邀请赛 (深圳)	银奖	2026.04
ICPC 国际大学生程序设计竞赛全国邀请赛 (南昌)	银奖	2026.05
第 21 届百度之星程序设计竞赛	全国银奖	2025.08
2026 中国高校计算机大赛 – 团体程序设计天梯赛 (个人)	全国银奖	2026.04
第 16 届蓝桥杯 C/C++ 程序设计本科 B 组	全国二等奖	2025.06
2024 RoboCom 睿抗机器人开发者大赛 – 编程设计赛道	全国二等奖	2024.08
第 15 届蓝桥杯 C/C++ 程序设计本科 B 组	全国二等奖	2024.06
CCPC 中国大学生程序设计竞赛全国邀请赛 (广东)	铜奖	2024.05

自我评价

本人长期关注人工智能安全研究, 围绕视觉语言预训练模型 (VLP) 和视觉语言动作模型 (VLA) 的对抗攻击、迁移性优化与攻击检测开展系统性探索。具备较强的科研执行力、实验复现与论文写作能力, 能够独立完成方法实现、实验设计、结果分析和图表绘制。同时具有扎实的程序设计基础和算法竞赛经验, 善于在复杂问题中进行分析、快速验证和持续优化。